



SISTEMAS INFORMÁTICOS DE AYUDA A LA DECISIÓN

INTEGRANTES:

- Maximiliano GRECO
- Víctor ISARRE
- Alejandro MARTINEZ
- Brando SALDAÑA
- Pablo YANES
- Miaomiao YANG

PROBLEMA

Dada una empresa, cinco clientes y unos costes de transporte constantes. ¿En dónde debería situar su almacén esta empresa?

De la empresa conocemos el historial de las demandas de los clientes desde 1995 hasta 2015 y su situación geográfica (Latitud y Longitud). Además son conocidos los costes por km.

$$\min_{x_0, y_0} \sum_{i=1}^5 w_i \cdot d_i \cdot c$$

$$d_i = \sqrt{(x_i - x_0)^2 + (y_i - y_0)^2}$$

DONDE:

- c : Coste unitario (€ / ud).
- w_i : Unidades demandadas de bienes (media de los últimos 3 años).
- d_i : Distancia al almacén.
- x_i : Coordenada eje x (Longitud, decimal).
- y_i : Coordenada eje y (Latitud, decimal).

con $i = \{1, \dots, 5\}$ (Clientes)

Variables de decisión: x_0, y_0

SIMULACIÓN

DEMANDA (CLIENTES)


SERIE TEMPORAL TIPO:

$$y_t = \delta_0 + \delta_1 \cdot t + u_t$$

Donde:

- y_t : Ventas para cada período t.
- δ_0 : Ventas independientes o autónomas. (Stock de Seguridad pe.)
- δ_1 : Pendiente la recta.
- u_t : Ruido $\sim N(0, 5)$

En este caso para darle más realismo, $\delta_0 = \delta_a + \delta_b \cdot \sin(x)$, de esta forma introducimos un posible componente estacional, que depende de cuán grande sea δ_b .



```
In [11]: ventas.head()
```

```
Out[11]:
```

	cliente1	cliente2	cliente3	cliente4	cliente5
1995-01-08	1057.125631	981.139096	993.012834	921.485244	1054.929112
1995-01-15	1058.038797	965.762513	991.368924	925.506056	1061.149308
1995-01-22	1050.353065	965.344514	991.796473	926.670731	1051.103377
1995-01-29	1053.505761	968.235378	993.462416	916.929766	1051.009594
1995-02-05	1052.877501	970.913001	997.258392	930.976354	1056.968813

In [12]: `ventas.tail()`

Out[12]:

	cliente1	cliente2	cliente3	cliente4	cliente5
2015-11-29	1089.545723	1156.598485	1210.117991	1337.511838	1470.752479
2015-12-06	1095.365517	1148.965002	1213.455964	1349.141883	1476.122176
2015-12-13	1095.118853	1155.781834	1207.221388	1341.626549	1469.859553
2015-12-20	1096.165708	1163.764572	1212.559956	1338.901084	1468.294863
2015-12-27	1084.971914	1150.177410	1214.876189	1347.971994	1460.618567

UBICACIÓN DE LOS CLIENTES

In [14]: data_clientes

Out[14]:

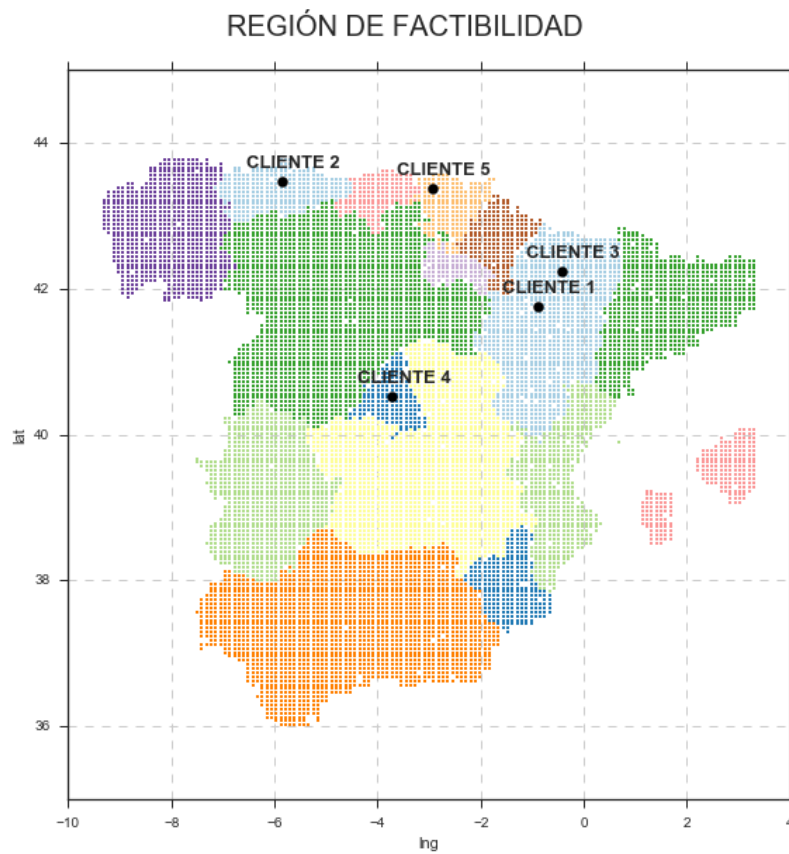
	prov	lat	lng
cliente1	zaragoza	41.648823	-0.889085
cliente2	oviedo	43.361915	-5.849389
cliente3	huesca	42.131845	-0.407806
cliente4	madrid	40.416775	-3.703790
cliente5	bilbao	43.263013	-2.934985

NOTA: En los mapas físicos, las coordenadas están expresadas en grados minutos y segundos, por ejemplo Madrid sería 40°25'08"N 3°41'31"O

Para convertir a decimal:

$$40^{\circ}25'08'' N = 40 + \frac{25}{60} + \frac{08}{3600} = 40.41888888888889$$
$$3^{\circ}41'31'' O = -(3 + \frac{41}{60} + \frac{31}{3600}) = -3.6919444444444447$$

La longitud se multiplica por **negativo**, porque está a la **izquierda (oeste)** del punto 0,0.



COSTES y PESOS

COSTE (c)

Datos: Observatorio de Costes del Transporte de Mercancías por Carretera (Enero 2015), para VEHÍCULO ARTICULADO DE CARGA GENERAL 1 (<http://www.fomento.gob.es/NR/rdonlyres/75019EB9-D1D4-48DD-B58C-91FBD81E8E3B/129718/ObservatorioCostesMercanciasenero2015.pdf>)

```
In [17]: c = (1.211 + 1.029) / 2
```

```
Out[17]: 1.12
```

PESO (w_i)

Suponemos que esta empresa ya maximiza beneficios dado los precios, es decir, la oferta igual a la demanda, siendo ésta última la previsión estimada como la media de los últimos 3 años.

$$w_i = \frac{1}{T} \cdot \sum_{t=2012}^{2015} (ventas_{it})$$

T = N° de observaciones entre 2012 y 2015

In [18]: `ventas.head()`

Out[18]:

	cliente1	cliente2	cliente3	cliente4	cliente5
1995-01-08	1057.125631	981.139096	993.012834	921.485244	1054.929112
1995-01-15	1058.038797	965.762513	991.368924	925.506056	1061.149308
1995-01-22	1050.353065	965.344514	991.796473	926.670731	1051.103377
1995-01-29	1053.505761	968.235378	993.462416	916.929766	1051.009594
1995-02-05	1052.877501	970.913001	997.258392	930.976354	1056.968813

```
In [19]: ventas.loc['2012:'].head()
```

```
Out[19]:
```

	cliente1	cliente2	cliente3	cliente4	cliente5
2012-01-01	1077.325321	1111.050666	1165.249280	1251.370094	1386.671676
2012-01-08	1078.676390	1110.072113	1173.512154	1264.479155	1383.848146
2012-01-15	1078.811238	1119.408951	1176.267080	1251.089708	1387.171679
2012-01-22	1082.287853	1115.102705	1161.736463	1256.147852	1375.243082
2012-01-29	1085.285927	1113.971479	1169.211906	1254.006147	1388.195087

```
In [20]: wi = ventas.loc['2012:'].mean()
```

```
In [22]: yxi['wi'] = wi  
        yxi
```

Out[22]:

	lat	lng	wi
cliente1	41.648823	-0.889085	1088.188049
cliente2	43.361915	-5.849389	1133.466342
cliente3	42.131845	-0.407806	1188.070200
cliente4	40.416775	-3.703790	1297.616717
cliente5	43.263013	-2.934985	1429.070507

OPTIMIZACIÓN

```
In [23]: def func_obj1(yx0):  
    'Función Obejtivo, xy0: Tupla, pares de coordenadas'  
    di = lambda yxj: vincenty(yx0, yxj).km  
    dist = yxi.apply(di, axis=1)  
    return sum(dist * wi) * c
```

```
In [25]: res1 = brute(func_obj1, rrange)
```

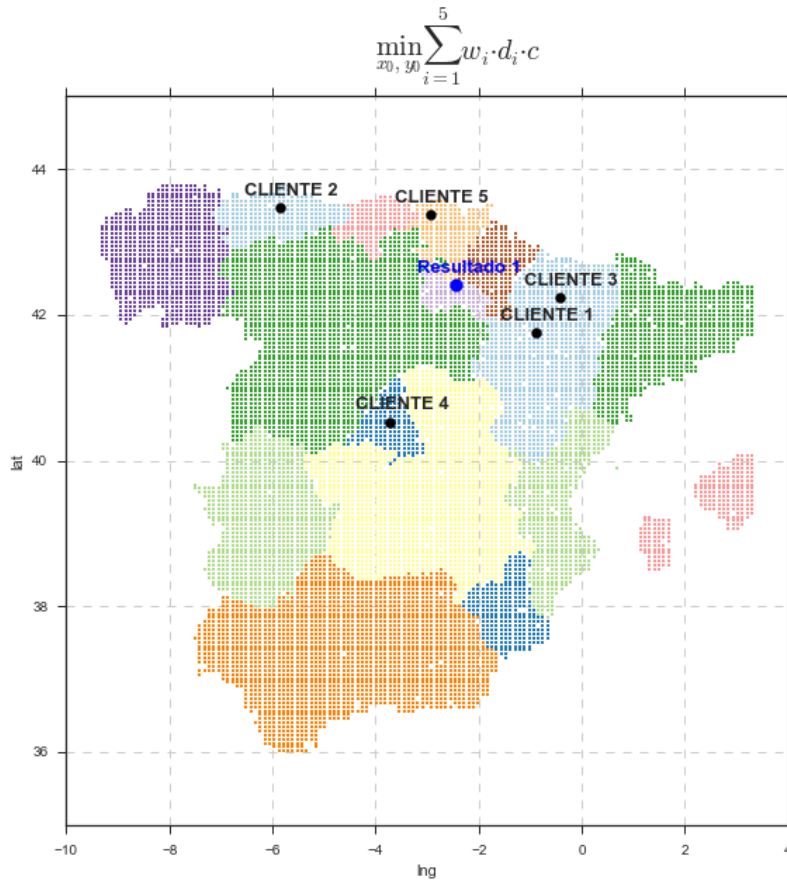
```
In [30]: r1(res1)
```

```
Out[30]:
```

RESULTADO:


- **LAT:** 42.3015617419
- **LONG:** -2.43768347258
- **CCAA:** RI: La Rioja
- **FUNCIÓN OBJETIVO:** 1312334.97165

RESULTADO DE LA PRIMERA OPTIMIZACIÓN




ANÁLISIS GRÁFICO

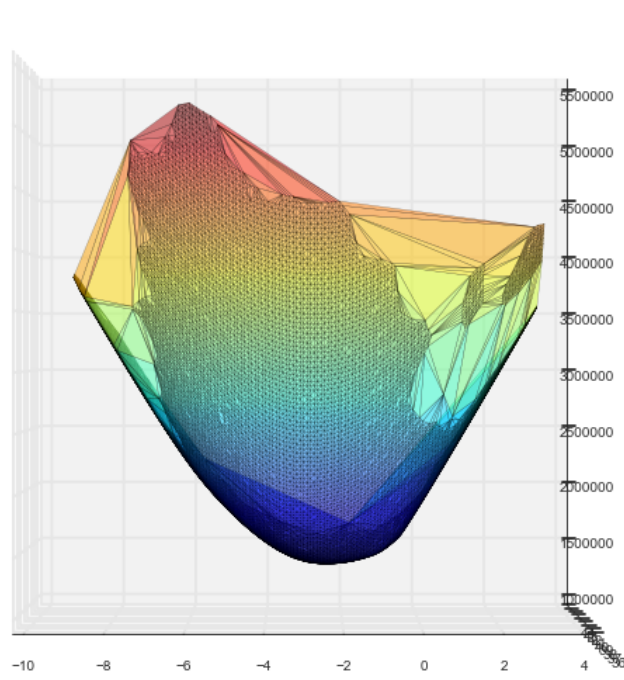
FUNCIÓN OBJETIVO 1 EVALUADA EN (x,y)



FUNCIÓN OBJETIVO 1 EVALUADA EN (x,y)



FUNCIÓN OBJETIVO 1 EVALUADA EN (x,y)



INTRODUCCIÓN DE UNA RESTRICCIÓN ADICIONAL

Al problema anterior, le agregamos una variable adicional de tipo fiscal. Cada comunidad autónoma pasará a cobrar un impuesto por unidad vendida, el tipo impositivo dependerá de la comunidad autónoma, de forma que los costes para la empresa cambien y por tanto la elección óptima.

PROBLEMA INICIAL + RESTRICCIÓN

$$\min_{x_0, y_0} \sum_{i=1}^5 w_i \cdot d_i \cdot c(1 + t)$$

s.a. $(x_0, y_0) \in \text{España}$

DONDE:

- c : Coste unitario (€/ud).
- w_i : Unidades demandadas de bienes (media de los últimos 3 años).
- d_i : Distancia al almacén (Km).
- x_i : Coordenada eje x (Longitud, decimal).
- y_i : Coordenada eje y (Latitud, decimal).
- t : Impuesto por unidad vendida.

Variables de decisión (Coordenadas): x_0, y_0

FUNCIÓN OBJETIVO CON IMPUESTOS

```
In [42]: def func_obj2(yx0):  
    'Función Obejtivo, xy0: Tupla, pares de coordenadas'  
    di = lambda yxj: vincenty(yx0, yxj).km  
    dist = yxi.apply(di, axis=1)  
    res = sum(dist * wi) * c * (1 + impuesto_ca(yx0))  
    return res
```

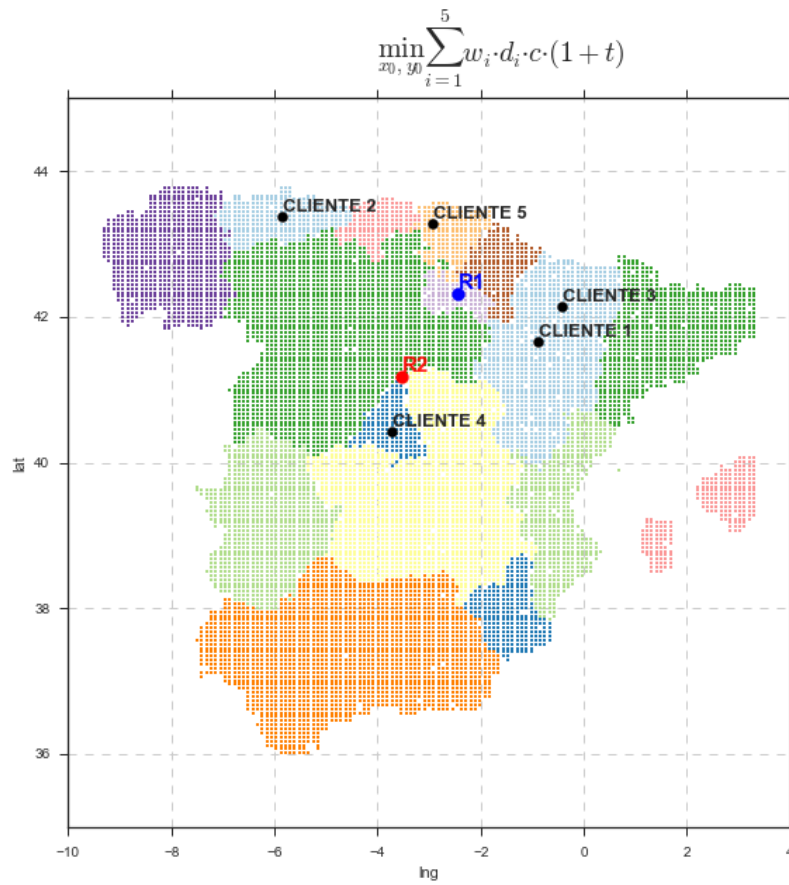
In [47]: `r2(res2)`


Out[47]:

RESULTADO:

- **LAT:** 41.1707155712
- **LONG:** -3.51401089789
- **CCAA:** MD: Madrid, Comunidad de
- **FUNCIÓN OBJETIVO:** 1562079.96239

RESULTADO DE LA SEGUNDA OPTIMIZACIÓN





```
In [65]: pd_res = pd.DataFrame.from_dict(resultados).T
pd_res.columns = ['lat', 'lng', 'fun_obj', 'ccaa']
#pd_res.to_csv('resultados.csv')
Markdown('# RESÚMEN\n' + pd_res.to_html())
```


Out[65]:

RESÚMEN

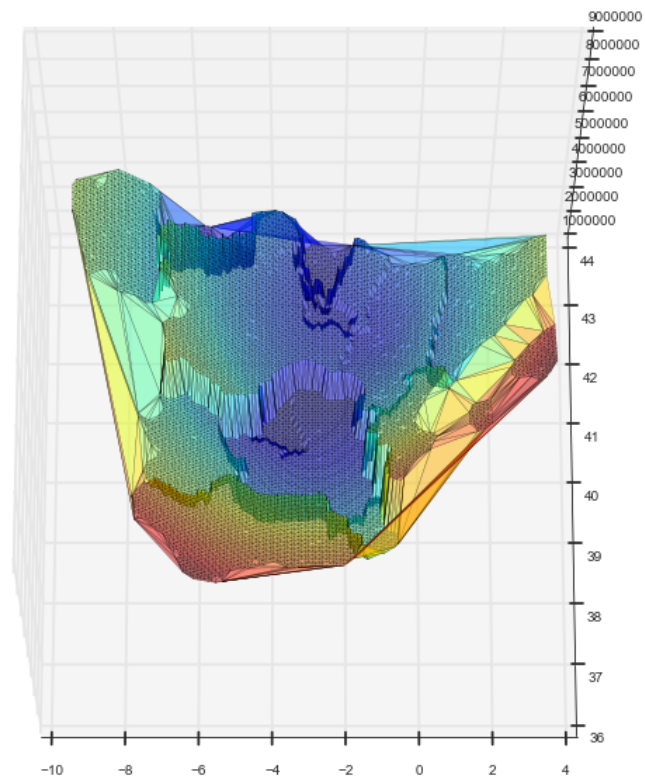
	lat	lng	fun_obj	ccaa
res1	42.3016	-2.43768	4.68691e+06	RI
res2	41.1707	-3.51401	5.57886e+06	MD

ANÁLISIS GRÁFICO


FUNCIÓN OBJETIVO 2 EVALUADA EN (x,y)




FUNCIÓN OBJETIVO 2 EVALUADA EN (x,y)



FUNCIÓN OBJETIVO 2 EVALUADA EN (x,y)



FUNCIÓN OBJETIVO 2 EVALUADA EN (x,y)



```
In [66]: ca_xys.head()
```

```
Out[66]:
```

	codigo	nombre	name.1	ti
name				
AN	ES-AN	Andalucía	AN	0.582215
AR	ES-AR	Aragón	AR	0.805577
AS	ES-AS	Asturias, Principado de	AS	0.034853
CN	ES-CN	Canarias	CN	0.642867
CB	ES-CB	Cantabria	CB	0.990424

MULTICRITERIO

MINIMIZAR EL PAGO IMPOSITIVO

Objetivo 1:

$$\min_{x_0, y_0} Z_1 = \sum_{i=1}^5 w_i \cdot t(x, y)$$

MINIMIZAR LOS COSTES DE TRASNSPORTE

Objetivo 2:

$$\min_{x_0, y_0} Z_2 = \sum_{i=1}^5 w_i \cdot d_i(x, y) \cdot c$$

Programación por metas MINIMAX o Tchebychev

$$\min\{\max D\}$$

sa:

- $Z_1 + n_1 - p_1 \leq 0.2$
- $Z_2 + n_2 - p_2$
 ≤ 200000
- $p_1/0.2 \leq D$
- $p_2/2000000 \leq D$
- $x, y \in \text{España}$

$$d_i = \sqrt{(x_i - x_0)^2 + (y_i - y_0)^2}$$

DONDE:

- c : Coste unitario (€/ud).
- w_i : Unidades demandadas de bienes (media de los últimos 3 años).
- d_i : Distancia al almacén (Km).
- x_i : Coordenada eje x (Longitud, decimal).
- y_i : Coordenada eje y (Latitud, decimal).
- t_j : Impuesto por unidad vendida. $j=\{1-16\}$

Variables de decisión (Coordenadas): x_0, y_0


```
In [67]: p1 = lambda yx: (impuesto_ca(yx) - 0.2) / 0.2
p2 = lambda yx: (func_obj1(yx) - 2000000) / 2000000

def fobj3(yx):
    return max(p1(yx), p2(yx))
```

```
In [68]: res3 = fmin(fobj3, res1)
```

```
Optimization terminated successfully.  
Current function value: 1.348887  
Iterations: 72  
Function evaluations: 139
```

In [75]: `res3`

Out[75]: `array([42.47386784, -2.53406359])`

```
In [76]: p1(_), p2(_)
```


```
Out[76]: (0.63608263254145392, 1.3488872033786961)
```

In [77]: `res_3(res3)`

Out[77]:

RESULTADO

- **LAT:** 42.4738678398
- **LONG:** -2.53406358903
- **CCAA:** PV
- **ti:** 0.327216526508
- **FUNC. OBJ.:** 4699782.34212





In [80]: `IFrame("https://www.google.com/maps/d/u/0/embed?mid=zTtXepJtMlLc.k6VXMPFTI7DI", width=940, height=580)`

Out[80]:

SIAD ☆



In [82]: data_clientes

Out[82]:

	prov	lat	lng	dist1	dist2
cliente1	zaragoza	41.648823	-0.889085	147.410125	225.796998
cliente2	oviedo	43.361915	-5.849389	302.771967	310.400117
cliente3	huesca	42.131845	-0.407806	168.657816	279.884499
cliente4	madrid	40.416775	-3.703790	234.601556	85.243187
cliente5	bilbao	43.263013	-2.934985	114.295030	237.271861

LIMITACIONES Y AMPLIACIONES

Errores de simplificación

- Se supone territorio es plano, no se tiene en cuenta la orografía. Se podría incluir la altitud en el análisis, para hacer el problema más real.

Distancia y Orografía

- La distancia entre cada punto es la recta que las une, introducir la distancia entre provincias en carretera sería más realista para hallar el lugar óptimo, pero muy costoso.
- Se ha usado el algoritmo de Vincenty para calcular la distancia entre dos puntos. ¹ ² (Español)

-
1. https://en.wikipedia.org/wiki/Vincenty%27s_formulae (https://en.wikipedia.org/wiki/Vincenty%27s_formulae)↵
 2. https://es.wikipedia.org/wiki/F%C3%B3rmulas_de_Vincenty (https://es.wikipedia.org/wiki/F%C3%B3rmulas_de_Vincenty)↵

Costes no reales.

- Los tipos impositivos han sido generados aleatoriamente a partir de una distribución uniforme 0,1. Bastaría sustituirlos por los reales para tener un resultado que se ajuste aún más a la realidad.

FIN

¡GRACIAS!